

# Comparação de heurísticas aplicadas no algoritmo A\*

Allan Diamante de Souza, 105423

Felipe Diniz Tomás, 110752

<sup>1</sup>Departamento de informática – Universidade Estadual de Maringá (UEM)  
Maringá – PR – Brasil

Modelagem e otimização Algoritmica – 6903

Ra110752@uem.br, Ra105423@uem.br

12, Abril 2021

## 1. Introdução

Publicado pela primeira vez em 1968 pelo grupo de pesquisadores do Instituto de pesquisa de Stanford<sup>1</sup>, o A-estrela (A\*) é um algoritmo de busca de caminho que utiliza uma combinação de aproximações heurísticas para resolver determinados tipos de problemas. A busca é realizada em um grafo começando de um vértice inicial, tendo como destino um vértice final. É frequentemente usado em muitos campos da ciência da computação devido à sua integridade, otimização e eficiência<sup>2</sup>, sendo suas principais aplicações voltadas a encontrar rotas de deslocamento entre localidades, além de ser preferencialmente utilizado em problemas de quebra-cabeça, como é o caso do N-Puzzle.

Por ser um algoritmo heurístico, um dos principais modificadores no desempenho do algoritmo A\* é a heurística aplicada, onde sua variação faz com que a execução siga diferentes caminhos. No entanto é notado que o algoritmo pode gerar um grande número de nós e que sua árvore de busca pode crescer exageradamente, resultando em um grande uso de memória em determinadas situações, mas como destacado por Zeng and Church (2009) continua sendo o melhor solução em muitos casos.

Sendo assim, o objetivo deste trabalho é analisar o comportamento do algoritmo A\* utilizando 5 heurísticas diferentes, para resolver o problema do quebra-cabeça 15-puzzle, observando o tempo de execução e uso de memória entre elas. As heurísticas aplicadas são: o número de peças foras de lugar (de acordo com o tabuleiro destino), o número de peças fora de ordem na sequência numérica das 15 peças (seguindo a ordem das posições no tabuleiro destino), o somatório da Distância Manhattan para cada peça fora do lugar, a combinação linear entre heurísticas e o máximo valor entre heurísticas.

## 2. O problema

O jogo 15-Puzzle, também conhecido como jogo das 15 peças, trata-se de um quebra-cabeças de quinze peças, composto por um tabuleiro com 15 números, que

---

<sup>1</sup> [https://en.wikipedia.org/wiki/A\\*\\_search\\_algorithm](https://en.wikipedia.org/wiki/A*_search_algorithm)

<sup>2</sup> [https://link.springer.com/chapter/10.1007%2F978-3-642-02094-0\\_7](https://link.springer.com/chapter/10.1007%2F978-3-642-02094-0_7)

trocam de lugar através de um espaço vazio. O objetivo é arranjar as peças em ordem, da esquerda para a direita, de cima a baixo<sup>3</sup>. É um problema popular para modelagem de heurísticas e utilização das mesmas.

O problema consiste em dado uma configuração inicial qualquer do tabuleiro, é necessário descobrir a quantidade mínima de movimentos sequenciais para chegar à configuração final do tabuleiro final. A seguir é possível observar um exemplo de uma configuração inicial para o tabuleiro 1, e o tabuleiro 2 final.

5		9	13
1	2	10	14
3	6	7	11
4	8	12	15

**Tabuleiro 1. Tabuleiro embaralhado**

1	5	9	13
2	6	10	14
3	7	11	15
4	8	12	

**Tabuleiro 2. Tabuleiro final**

### 3. Algoritmo A\*

O algoritmo A\* é um algoritmo para Busca de Caminho, que realiza a busca do caminho em um grafo de um vértice inicial até um vértice final. O processo utiliza uma estrutura de árvore de nós sucessores originados de nós pais, que se expande indefinidamente a cada iteração até alcançar o nó objetivo.

Para determinar qual nó sucessor seguir, o algoritmo realiza o cálculo da função  $f(n)$  em cada iteração. Essa função irá determinar através de um valor qual nó sucessor chega mais próximo do nó final, guiando assim as próximas iterações do algoritmo. Esta função é dada por:

$$f(n) = g(n) + h(n)$$

No qual:

- $g(n)$  é o custo do nó inicial até o nó  $n$
- $h(n)$  é uma aproximação fornecida pela função heurística do custo do nó  $n$  até o nó objetivo.

---

<sup>3</sup> <https://zenodo.org/record/979689>

## 4. Heurísticas

Como explicado anteriormente o algoritmo A\* deve aplicar determinada heurística a fim de encontrar o caminho. Através delas é possível identificar a eficiência de cada uma, e como a mesma afeta o processo de execução.

### 4.1. $h'_1(n)$ – Número de peças fora de lugar

Esta heurística consiste na contagem de peças fora do lugar tendo como base a configuração final. Considerando o exemplo do Tabuleiro 1 e o Tabuleiro 2, visto na seção 2, o a heurística retornará 8 peças fora do lugar. A complexidade desta heurística é linear já que percorrerá sequencialmente todo o tabuleiro verificando cada peça, logo como o tabuleiro permanece do mesmo tamanho, o tempo de execução é constante para cada chamada heurística.

### 4.2. $h'_2(n)$ – Número de peças fora de ordem de acordo com a sequência numérica

Esta heurística consiste na contagem de peças fora do lugar tendo como base a configuração final. Basicamente a heurística olha para cada peça e verifica se a próxima na sequência (de acordo com o tabuleiro final) é sua sucessora em ordem numérica. Por exemplo, em uma peça de valor 5, espera-se que apróxima na sequência seja a número 6, caso contrário contabiliza fora de ordem.

No Tabuleiro 1 visto na seção 2, tem como retorno 9 peças fora de ordem, sendo elas em amarelo:

5	1	3	4	0	2	6	8	9	10	7	12	13	14	11	15
---	---	---	---	---	---	---	---	---	----	---	----	----	----	----	----

**Tabela 1. Peças fora de ordem**

A complexidade da heurística é linear, já que deve percorrer todo o tabuleiro verificando as peças fora de ordem. A execução ocorre em tempo constante dado o tamanho fixo do tabuleiro.

### 4.3. $h'_3(n)$ – Distância Manhattan

Esta heurística consiste no cálculo da distância Manhattan entre cada peça e seu respectivo lugar na configuração final. Ou seja, para cada peça fora de seu lugar soma a distância Manhattan (quantidade de deslocamentos) para colocar em seu devido lugar.

De maneira mais formal, podemos definir a distância de Manhattan entre dois pontos num espaço euclidiano com um sistema cartesiano de coordenadas fixo como a soma dos comprimentos da projecção da linha que une os pontos com os eixos das coordenadas<sup>4</sup>.

Por exemplo, num plano que contem os pontos  $P_1$  e  $P_2$ , respectivamente com as coordenadas  $(x_1, y_1)$  e  $(x_2, y_2)$  é definido por:

$$|x_1 - x_2| + |y_1 - y_2|$$

---

<sup>4</sup> [https://pt.wikipedia.org/wiki/Geometria\\_pombalina](https://pt.wikipedia.org/wiki/Geometria_pombalina)

Quando aplicado ao tabuleiro 15-puzzle,  $P_1$  passa a ser a peça do tabuleiro desornado e  $P_2$  a mesma peça no tabuleiro final. Novamente a complexidade deste algoritmo depende do tamanho do tabuleiro.

#### 4.4. $h'_4(n)$ – Combinação linear entre heurísticas

Nesta heurística ocorrerá a soma do resultado de heurísticas anteriores multiplicado por pesos,  $p_1, p_2, p_3$  que totalizam 1.

$$p_1 * h'_1(n) + p_2 * h'_2(n) + p_3 * h'_3(n)$$

Onde foi definido:

- $p_1 = 0.3$
- $p_2 = 0.2$
- $p_3 = 0.5$

A complexidade depende das heurísticas anteriores, assim como seu tempo de execução.

#### 4.5. $h'_4(n)$ – Máximo entre as heurísticas

Esta heurística utilizará o máximo das heurísticas anteriores, portanto sua complexidade também depende das mesmas.

$$\max(h'_1(n), h'_2(n), h'_3(n)).$$

### 5. Metodologia

Quando se trata de metodologia, foi necessário estabelecer recursos para que os testes possam ser feitos de forma justa. Esta seção dica-se a explicar os métodos e recursos utilizados no projeto.

#### 5.1. Máquina

Foi utilizado uma máquina pessoal com as configurações a seguir<sup>5</sup>:

- Processador: Intel(R) Core(TM) i7-3770k CPU @ 3.50GHz;
- Memória RAM: 16.0GB;
- Disco: 100.6GB;
- GPU: RX580 8gb
- OS: Windows 10 Home

#### 5.2. Linguagem

A linguagem utilizada foi o *python* 3.8<sup>6</sup>.

---

<sup>5</sup> <https://towardsdatascience.com/colab-pro-is-it-worth-the-money-32a1744f42a8>

<sup>6</sup> <https://docs.python.org/>

### 5.3. Métrica de tempo e memória

Para calcular o tempo de execução foi utilizado o módulo `time.time()`<sup>7</sup> e a verificação de memória através da biblioteca `sys`<sup>8</sup> utilizando o método `getsizeof()` dos conjuntos A e F combinados.

### 5.4. Estrutura dos dados

Ao implementar o algoritmo A\* é necessário estabelecer uma estrutura de dados para armazenar adequadamente os conjuntos A e F, além da estrutura dos nós.

- O conjunto A: estados que já foram gerados, mas ainda não foram processados pelo algoritmo;
- O conjunto F: estados que já foram processados pelo algoritmo.

No projeto o nó foi estruturado como uma classe (*Node*), possuindo o estado do tabuleiro (*state*), o pai que gerou o nó (*parent*), o custo de  $g(n)$  (*gcost*) o custo de  $h(n)$  (*hcost*) e uma função para cálculo de  $f(n)$ , como é mostrado na Figura 1.

```
class Node:
    def __init__(self, state, parent, gcost = 0, hcost = 0):
        self.state = state
        self.gcost = gcost
        self.parent = parent
        self.hcost = hcost

    def f(self):
        return self.gcost + self.hcost
```

Figura 1. Classe Node

A estrutura fundamental do código A\* é a do conjunto A e F, que foi implementado em tabela hash, que existe por padrão em python com o uso de dicionário. As tabelas hash tem como chave uma *string* com o estado do tabuleiro (*iniTable.state*) e o nó (*iniTable*). Além disso, foi necessário uma estrutura de heap para armazenar o valor da função  $f(n)$  e a respectiva chave do dicionário. Como mostrado na figura a seguir:

```
heap = [(iniTable.f(), iniTable)]
A = {str(iniTable.state) : iniTable}
F = {}
```

Figura 2. Estrutura do conjunto A e F

Através da biblioteca *heapq*<sup>9</sup> é possível utilizar a estrutura heap como heap mínimo, para que seja possível recuperar o menor valor de  $f(n)$  sem percorrer todo conjunto A. Buscar uma chave em dicionário tem tempo constante de  $O(1)$  e encontrar

---

<sup>7</sup> <https://pypi.org/project/ipython-autotime/>

<sup>8</sup> <https://docs.python.org/3/library/sys.html>

<sup>9</sup> <https://docs.python.org/3/library/heapq.html>

o mínimo em um heap mínimo pode ser feito em tempo constante, por fim verificar se um valor está em um dicionário tem tempo  $O(n)$ .

### 5.5 Análise das linhas 9 e 10 do algoritmo A\* (versão II)

As linhas 9 e 10 são responsáveis pela otimização da árvore, ou seja, dado um estado do tabuleiro (nó), essa parte do código irá verificar se o estado já foi descoberto anteriormente e está no conjunto A, se sim, caso o caminho atual encontrado para esse nó for menor (considerando  $g(n)$ ) do que o que está em A, irá removê-lo de A.

Esse processo do algoritmo influencia diretamente no uso de recurso do mesmo. A memória não armazenará caminhos que foram encontrados com o maior  $g(n)$  otimizando o armazenamento, conseqüentemente o desempenho de processamento também é afetado por não processar os caminhos desnecessário.

## 6. Casos de testes

Dez configurações iniciais para o tabuleiro foram fornecidas pelo professor, (onde 0 representa o espaço em branco), para a comparação das heurísticas. Os testes são:

Testes	Configuração inicial
1	0 2 9 13 3 1 5 14 4 7 6 10 8 11 12 15
2	3 2 1 9 0 5 6 13 4 7 10 14 8 12 15 11
3	2 1 9 13 3 5 10 14 4 6 11 15 7 8 12 0
4	9 13 10 0 5 2 6 14 1 7 11 15 3 4 8 12
5	4 3 2 1 8 10 11 5 12 6 0 9 15 7 14 13
6	9 13 14 15 5 6 10 8 0 1 11 12 7 2 3 4
7	10 6 2 1 7 13 9 5 0 15 14 12 11 3 4 8
8	6 2 1 5 4 10 13 9 0 8 3 7 12 15 11 14
9	10 13 15 0 5 9 14 11 1 2 6 7 3 4 8 12
10	5 9 13 14 1 6 7 10 11 15 12 0 8 2 3 4

**Tabela 2. Casos testes**

A partir das configurações iniciais poderá ser testado o consumo de tempo e de memória em cada heurística, comparando o desempenho das mesmas. O consumo de memória é interessante pois é um dos possíveis limitadores do algoritmo A\*, logo rastrear a quantidade de memória sendo utilizada é essencial para medir a eficiência do algoritmo.

## 7. Resultado e análise

A seguir veremos o número de movimentos mínimos para chegar ao tabuleiro final para cada caso de teste, ou seja o resultado esperado pelo algoritmo.

Testes	Número de movimentos
1	18
2	19
3	12
4	21
5	38
6	32
7	38
8	32
9	27
10	29

**Tabela 3. Casos testes**

Agora podemos partir para análise das métricas de memória e tempo.

## 7.2. Consumo de memória

O consumo de memória, de acordo com a heurística, é o principal fator limitante do algoritmo A\*. Em algumas das heurística não foi possível executar todos os teste pois houve estouro de memória. A seguir a Tabela 4 indica a quantidade de memória utilizada em cada teste por cada uma das cinco heurísticas. “N/A” indica que houve estouro de memória.

Testes	$h'_1(n)$	$h'_2(n)$	$h'_3(n)$	$h'_4(n)$	$h'_5(n)$
1	46 KB	110.7 KB	3.48 KB	14.08 KB	6.9 KB
2	27 KB	221.3 KB	1.8 KB	6.9 KB	3.4 KB
3	2.9 KB	6.96 KB	1.8 KB	1.8 KB	1.8 KB
4	110 KB	442.5 KB	14.0 KB	27.8 KB	14 KB
5	N/A	N/A	6.98 KB	7.86 MB	6.9 KB
6	62.90 MB	N/A	14.0 KB	884.9 KB	221.3 KB
7	N/A	N/A	27.8 KB	31.4 MB	1.90 MB
8	83.88 MB	251.6 MB	55.4 KB	1.9 MB	110.7 KB
9	3.93 MB	125.8 MB	3.44 KB	184.5 KB	110.7 KB
10	31.45 MB	167.7 MB	110.7 KB	884.9 KB	442.5 KB

**Tabela 4. Consumo de memória**

## 7.2. Consumo de tempo

Quando se trata do consumo de tempo, como já explicado anteriormente, cada heurística pode influenciar muito no desempenho do algoritmo, fazendo com que uma seja computacionalmente viável e outra não. Essa diferença resulta em um comportamento diretamente ligado ao tempo, podendo demorar mais para chegar ao resultado esperado. É importante ressaltar que a prioridade da implementação neste projeto foi o tempo e não o consumo de memória. A seguir na Tabela 5 podemos ver os resultados de cada teste para cada uma das 5 heurísticas aplicadas.

Testes	$h'_1(n)$	$h'_2(n)$	$h'_3(n)$	$h'_4(n)$	$h'_5(n)$
1	0.05 s	0.1 s	0.005 s	0.019 s	0.011 s
2	0.008 s	0.331 s	0.006 s	0.011 s	0.008 s
3	0.003 s	0.009 s	0.004 s	0.006 s	0.004 s
4	0.146 s	0.437 s	0.015 s	0.04 s	0.026 s
5	N/A	N/A	0.009 s	10.115 s	0.013 s
6	1654.09 s	N/A	0.019 s	1.899 s	0.354 s
7	N/A	N/A	0.041 s	43.304 s	4.604 s
8	3195.30 s	6839.46 s	0.056 s	2.069 s	0.158 s
9	3.78 s	3990.22 s	0.004 s	0.306 s	0.19 s
10	549.5 s	5087.92 s	0.125 s	1.811 s	0.783 s

**Tabela 5. Consumo de tempo (em segundos)**

### 7.3 Análise entre as heurísticas

Este tópico analisará dentre os testes, qual método teve o melhor desempenho de tempo e o menor consumo de memória. A seguir veremos algumas tabelas de comparação de tempo médio e memória média entre cada heurística dos testes que não houveram estouro, visto na tabela 3 e 4 anteriormente.

Tempo médio $h'_1(n)$	Memória média $h'_1(n)$
4.25 vezes mais rápido que $h'_2$	$h'_2$ utiliza 464% do espaço da $h'_1$
16,020 vezes mais lento que $h'_3$	$h'_3$ utiliza 0.16% do espaço da $h'_1$
879 vezes mais lento que $h'_4$	$h'_4$ utiliza 1.81% do espaço da $h'_1$
2,443 vezes mais lento que $h'_5$	$h'_5$ utiliza 0.59% do espaço da $h'_1$

**Tabela 5. Comparação da  $h'_1(n)$  com as demais heurísticas**

Tempo médio $h'_2(n)$	Memória média $h'_2(n)$
4.25 vezes mais lento que $h'_1$	$h'_1$ utiliza 21.55% do espaço da $h'_2$
68,020 vezes mais lento que $h'_3$	$h'_3$ utiliza 0.04% do espaço da $h'_2$
3,730 vezes mais lento que $h'_4$	$h'_4$ utiliza 0.39% do espaço da $h'_2$
10,37 vezes mais lento que $h'_5$	$h'_5$ Utiliza 0.13% do espaço da $h'_2$

**Tabela 6. Comparação da  $h'_2(n)$  com as demais heurísticas**

Tempo médio $h'_3(n)$	Memória média $h'_3(n)$
16,020 vezes mais rápida que $h'_1$	$h'_1$ utiliza 61,477% do espaço da $h'_3$
68,027 vezes mais rápida que $h'_2$	$h'_2$ utiliza 285,271% do espaço da $h'_3$
18 vezes mais rápida que $h'_4$	$h'_4$ utiliza 1,113% do espaço da $h'_3$
6.5 vezes mais rápida que $h'_5$	$h'_5$ utiliza 362% do espaço da $h'_3$

**Tabela 7. Comparação da  $h'_3(n)$  da com as demais heurísticas**



Tempo médio $h'_4(n)$	Memória média $h'_4(n)$
879.5 vezes mais rápida que $h'_1$	$h'_1$ utiliza 5,525% do espaço da $h'_4$
3,734 vezes mais rápida que $h'_2$	$h'_2$ utiliza 25,640% do espaço da $h'_4$
18 vezes mais lenta que $h'_3$	$h'_3$ utiliza 9% do espaço da $h'_4$
2.78 vezes mais lenta que $h'_5$	$h'_5$ utiliza 33% do espaço da $h'_4$

**Tabela 8. Comparação da  $h'_4(n)$  da com as demais heurísticas**

Tempo médio $h'_5(n)$	Memória média $h'_5(n)$
2,443 vezes mais rápida que $h'_1$	$h'_1$ utiliza 16,984% do espaço da $h'_5$
10,377 vezes mais rápida que $h'_2$	$h'_2$ utiliza 78,809% do espaço da $h'_5$
6.56 vezes mais lenta que $h'_3$	$h'_3$ utiliza 28% do espaço da $h'_5$
2.78 vezes mais rápida que $h'_4$	$h'_4$ utiliza 307% do espaço da $h'_5$

**Tabela 9. Comparação da  $h'_5(n)$  da com as demais heurísticas**

É perceptível que após todos os testes processados a  $h'_2(n)$  (peças fora de ordem de acordo com a sequência numérica) é a mais custosa, tanto em tempo quanto em memória comparada as demais (Tabela 6). Já a heurística mais rápida e com menor consumo de memória é a  $h'_3(n)$  (distância Manhattan) (Tabela 7). Também notou-se que tanto a heurística 1 quanto a heurística 2 não foram capazes de processar todos os testes, pois houve estouro de memória.

## 8. Conclusão

Conclui-se que a estrutura de dados árvore A\* é influenciada pela heurística aplicada pra resolução do problema, porém caso utilizado uma heurística ineficiente o algoritmo gerará uma árvore muito profunda, consumindo muita memória e tempo.

Após analisarmos cada heurística aplicada na árvore A\*, fica nítido a discrepância de desempenho entre as heurísticas, sendo a heurística 3 (distância Manhattan) a melhor delas. Isso ocorre porque a heurística 3 diferente das demais, contabiliza uma informação mais precisa de cada elemento do tabuleiro do que as outras heurísticas, melhorando a escolha dos seus sucessores.

Em trabalhos futuros pode ser realizado mais testes para melhorar a precisão das comparações entre as heurísticas.

## Referências

Zeng, W.; Church, R. L. (2009). "Finding shortest paths on real road networks: the case for A\*". *International Journal of Geographical Information Science*.